Varianzanalyse

Cooler Untertitel, den wir uns noch ausdenken

Henri Neumann & Robert Feldhans

15. Dezember 2016

Experimentelle Psychologie für Nichtpsychologen

Inhalt

- 1. Einführung
- 2. Prinzip der Varianzanalyse
- 3. Rechnung an Tafel
- 4. Robert
- 5. Historische Einordnung
- 6. Malware und ihre Hauptverteilwege
- 7. Antiviren-Programme

Einführung

Einführung

Definition

Verfahren, welches die Wirkung einer (oder mehrerer) UV auf eine (oder mehrerer) AV untersucht.

- testet Unterschiede zw. Mittelwerten auf Signifikanz
- Einsatz bei mehr als 2 Stichproben
- Häufig auch als Globaltest bezeichnet

Grundbegriffe

- Zielvariable: abhängige Variable(AV)
- Faktor: unabhängige Variable(UV)
- Faktorstufen: Ausprägungen/Kategorien eines Faktors
- Effekt: Wirkung eines Faktors auf die AV
- Interaktionseffekt: kombinierte Wirkung zweier Faktoren auf die AV

Unterteilung

Abgrenzung anhand von Anzahl abhängige Variablen und Faktoren

Zahl der AVn	Zahl der UVn	Bezeichnung				
1	1	Einfaktorielle VA				
1	2	Zweifaktorielle VA				
1	3	Dreifaktorielle VA				
	usw.					
≥ 2	≥ 1	Multivariante VA				

Vorraussetzungen

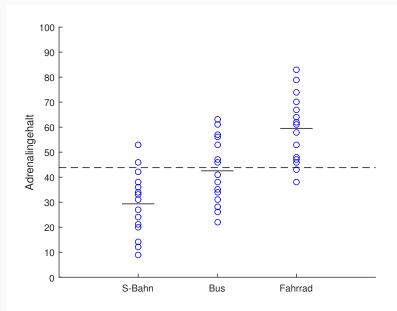
- Fehlerkomponenten sind normalverteilt
- Fehlervarianzen homogen in den Faktorstufen
- Messwerte bzw. Faktorstufen sind unabhängig voneinander

Prinzip der Varianzanalyse

Die gesamte Varianz der AV wird aufgeteilt in:

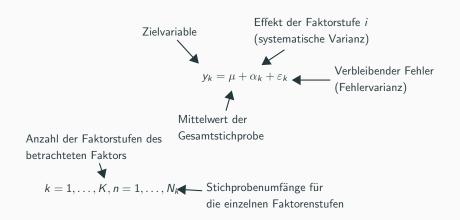
- Varianz zwischen Gruppen:
 Abweichung der Gruppenmittelwerte vom Gesamtmittelwert
 = systematische Varianz
- Varianz innerhalb von Gruppen:
 Abweichung einzelner Messwerte vom Gruppenmittelwert
 unsystematische Varianz, Fehlervarianz
- ⇒ anschließend Vergleich der Varianzschätzungen

Beispiel



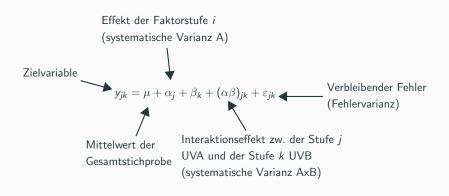
Mathematisches Modell

Allgemeines Modell der einfaktoriellen Varianzanalyse



Mathematisches Modell

Allgemeines Modell der zweifaktoriellen Varianzanalyse



Hypothesen

einfaktoriell

• Nullhypothese:

Alle Mittelwerte sind gleich oder alle Effekte α_k sind 0.

Formal: $H_0: \mu_1 = \mu_2 = \cdots = \mu_k \text{ oder } \sum \alpha_k^2 = 0$

• Alternativhypothese:

Nicht alle Mittelwerte sind gleich oder mindestens ein Effekt α_i ist ungleich Null.

Formal: $H_1: \sum (\mu_k - \mu)^2 > 0$ oder $\sum \alpha_k^2 > 0$

Hypothesen

zweifaktoriell

Für jeden Faktor wird eine Nullhypothese überprüft

• Faktor A:

Alle Zeilenmittelwerte sind gleich oder alle Effekte α_j sind 0.

Formal:
$$H_0: \mu_{1\cdot} = \mu_{2\cdot} = \cdots = \mu_{J\cdot}$$
 oder $\sum \alpha_j^2 = 0$

• Faktor B:

Alle Spaltenmittelwerte sind gleich oder alle Effekte β_k sind 0.

Formal:
$$H_0: \mu_{\cdot 1} = \mu_{\cdot 2} = \cdots = \mu_{\cdot K}$$
 oder $\sum \beta_k^2 = 0$

• Interaktion AB:

Die Wirkung der einzelnen UVn auf die AV ist voneinander abhängig.

Formal:
$$H_0: \bar{y}_{jk} = \mu_{\cdot k} + \mu_{j\cdot} - \mu + \varepsilon$$

Zweifaktorielle Varianzanalyse

			Zeilenmittel				
		B_1	B_2		B_K	HE A	
UV A	A_1	μ_{11}	μ_{12}		μ_{1K}	$= \mu_1.$ $= \mu + \alpha_1$	
	A_2	μ_{21}				$\mu_2.$ $= \mu + \alpha_2$	
						$= \mu_j.$ $= \mu + \alpha_j$	
	A_J	μ_{J1}			μ JK	$\mu_{J.} = \mu + \alpha_{J}$	
Spalten- mittel	НЕ В	$\mu \cdot 1 = \mu + \beta_1$	$\mu \cdot 2 = \mu + \beta_2$	$\mu \cdot k = \mu + \beta_k$	$\mu \cdot \kappa = \mu + \beta_K$	μ	

Prinzip der Varianzanalyse

Prinzip der Varianzanalyse

Die gesamte Varianz der AV wird aufgeteilt in:

- Varianz zwischen Gruppen:
 Abweichung der Gruppenmittelwerte vom Gesamtmittelwert
 = systematische Varianz
- Varianz innerhalb von Gruppen:
 Abweichung einzelner Messwerte vom Gruppenmittelwert
 unsystematische Varianz, Fehlervarianz
- ⇒ anschließend Vergleich der Varianzschätzungen

Summe der Abweichungsquadrate

Repräsentiert die Unterschiedlichkeit der Werte der AV. Drei relevante Formen:

- SAQ_{Gesamt} : Die Gesamtvariabilität. Formal: $SAQ_{Gesamt} = \sum (y - \bar{y})^2$
- SAQ_{Effekt}: auch SAQ_{zwischen}; Variabilität zwischen Bedingungen.

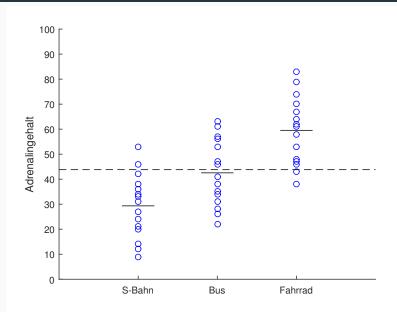
Formal:
$$SAQ_{Effekt} = n_k \sum_{k=1}^{K} (\bar{y}_k - \bar{y})^2$$

 SAQ_{Fehler}: auch SAQ_{innerhalb}; Variabilität innerhalb einer Bedingung.

Formal:
$$SAQ_{Fehler} = \sum (y - \bar{y}_k)^2$$

$$\mathsf{Es}\;\mathsf{gilt}\;\mathsf{SAQ}_\mathsf{Gesamt} = \mathsf{SAQ}_\mathsf{Effekt} + \mathsf{SAQ}_\mathsf{Fehler}$$

Beispiel



Freiheitsgrade (FG)

Anzahl der frei variierbaren Werte oder auch Anzahl der in die SAQ eingehenden Werte

- *SAQ_{Gesamt}*: *N* − 1
- SAQ_{Effekt} : K-1 K: Anzahl Faktorstufen
- SAQ_{Effekt} : $K \cdot (n-1)$

 $\textbf{Es gilt } \textbf{FG}_{\textbf{Gesamt}} = \textbf{FG}_{\textbf{Effekt}} + \textbf{FG}_{\textbf{Fehler}}$

Mittlere Quadratsumme (MQ)

- Die mittlere Quadratsumme entspricht der Varianz
- MQ_{Fehler}: Schätzung der Populationsvarianz
- MQ_{Effekt}: Schätzung der Populationsvarianz wenn H₀ gilt
- Mittlere Quadratsummen sind nicht additiv

$$MQ = \frac{SAQ}{FG}$$

Bedeutung der MQ

- $MQ_{Effekt} = MQ_{Fehler}$: H_0 ist gültig
- MQ_{Effekt} » MQ_{Fehler}: H₀ ist ungültig, MQ_{Effekt} enthält systematische Varianz

Aber: Wann ist MQ_{Effekt} überzufällig größer als MQ_{Fehler} ?

Bedeutung der MQ

- $MQ_{Effekt} = MQ_{Fehler}$: H_0 ist gültig
- $MQ_{Effekt} \gg MQ_{Fehler}$: H_0 ist ungültig, MQ_{Effekt} enthält systematische Varianz

Aber: Wann ist MQ_{Effekt} überzufällig größer als MQ_{Fehler} ?

⇒ Prüfen mit F-Verteilung

$$F = \frac{MQ_{Effekt}}{MQ_{Fehler}}, FG = K - 1, K(n - 1)$$

F-Verteilung

Wenn $F_{empirisch} > F_{kritisch} \Rightarrow$ Ablehnung von H_0

n m	1	2	3	4	5	6	7	8	9	10	12	15	20	30	40	50
1	161	200	216	225	230	234	237	239	241	242	244	246	248	250	251	252
2	18,5	19,0	19,2	19,3	19,3	19,3	19,4	19,4	19,4	19,4	19,4	19,4	19,5	19,5	19,5	19,5
3	10,1	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79	8,74	8,70	8,66	8,62	8,59	8,58
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,91	5,86	5,80	5,75	5,72	5,70
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74	4,68	4,62	4,56	4,50	4,46	4,44
6	5,99	5,14	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,00	3,94	3,87	3,81	3,77	3,75
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64	3,58	3,51	3,44	3,38	3,34	3,32
8	5,32	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,35	3,28	3,22	3,15	3,08	3,04	3,02
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14	3,07	3,01	2,94	2,86	2,83	2,80
10	4,96	4,10	3,71	3,48	3,33	3,22	3,13	3,07	3,02	2,98	2,91	2,85	2,77	2,70	2,66	2,64
11	4,84	3,98	3,59	3,36	3,20	3,10	3,01	2,95	2,90	2,85	2,79	2,72	2,65	2,57	2,53	2,51
12	4,75	3,88	3,49	3,26	3,11	3,00	2,91	2,85	2,80	2,75	2,69	2,62	2,54	2,47	2,43	2,40
13	4,67	3,81	3,41	3,18	3,02	2,92	2,83	2,77	2,71	2,67	2,60	2,53	2,46	2,38	2,34	2,31
14	4,60	3,74	3,34	3,11	2,96	2,85	2,76	2,70	2,65	2,60	2,53	2,46	2,39	2,31	2,27	2,24
15	4,54	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,59	2,54	2,48	2,40	2,33	2,25	2,20	2,18
16	4,49	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,42	2,35	2,28	2,19	2,15	2,12
17	4,45	3,59	3,20	2,96	2,81	2,70	2,61	2,55	2,49	2,45	2,38	2,31	2,23	2,15	2,10	2,08
18	4,41	3,56	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,34	2,27	2,19	2,11	2,06	2,04
19	4,38	3,52	3,13	2,90	2,74	2,63	2,54	2,48	2,42	2,38	2,31	2,23	2,15	2,07	2,03	2,00
20	4,35	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,39	2,35	2,28	2,20	2,12	2,04	1,99	1,97
21	4,33	3,47	3,07	2,84	2,68	2,57	2,49	2,42	2,37	2,32	2,25	2,18	2,10	2,01	1,97	1,94
22	4,30	3,44	3,05	2,82	2,66	2,55	2,46	2,40	2,34	2,30	2,23	2,15	2,07	1,98	1,94	1,91
23	4,28	3,42	3,03	2,80	2,64	2,53	2,44	2,38	2,32	2,27	2,20	2,13	2,05	1,96	1,91	1,88
24	4,26	3,40	3,01	2,78	2,62	2,51	2,42	2,35	2,30	2,25	2,18	2,11	2,03	1,94	1,89	1,86
25	4,24	3,38	2,99	2,76	2,60	2,49	2,40	2,34	2,28	2,24	2,16	2,09	2,01	1,92	1,87	1,84

Maß der Effektgröße

Eta²

Anteil der Variation in den Daten, der durch die Variation der UV erklärt werden kann.

$$\eta^2 = \frac{SAQ_{Effekt}}{SAQ_{Gesamt}}$$

Klassifikation nach Cohen:

• klein: 0.01

• mittel: 0.06

• groß: 0.14

Rechnung an Tafel

Robert

Historische Einordnung

Beginn des Schlangenöls

- aus Mythologie des Wilden Westens
- von Wunderheilern eingesetzt
- Heilmittel für Gebrechen aller Art



Schlangenöl allgemein

- versprochenes Wundermittel
- unübersichtliche Bereiche, oft in Technik
- wenig Wirkung
- Heutige Anwendungen oft in Kryptografie und Antiviren-Software

Malware und ihre Hauptverteilwege

Malware

Malware

Software, welche schädliche Funktionen ausführen

- Viren
- Würmer
- Trojanische Pferde
- Ransomware
- ..
- nicht: fehlerhafte Software

Verschiedene Malware

Virus

Schadprogramm, welches sich verbreitet, in dem es sich in andere Software einschleust. Durch das Kopieren dieser wird der Virus passiv verbreitet (und dabei oft nur lokal)

Wurm

Schadprogramm, welches sich aktiv ausbreitet, in dem es Sicherheitsprobleme ausnutzt. Für Nutzer kaum unterschiedlich zu Viren

Trojanisches Pferd

Schadprogramm, welches sich als nützliche Anwendung tarnt und ohne Wisse des Anwenders (auch) schädliche Funktionen ausführt

Anzahl Malware

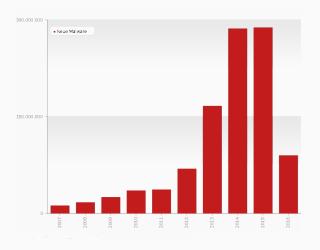


Abbildung 1: Registrierung neuer Schadprogramme in den letzten 10 Jahren. Quelle: avtest

Verteilwege von Malware

- E-Mail-Dateianhänge
- Drive-by-Downloads
- Datenträger
- Netzwerke

Statistiken

Problem

Viele Statistiken zu Malware und ihren Verteilwegen werden von Antiviren-Software-Firmen angeboten

- wenige unabhängige Quellen
- Quantität schwer einzuschätzen
- nur bekannte Probleme aufgelistet

Antiviren-Programme

Vermeintliche Lösung

Wie schützen wir uns vor Viren?

Wir installieren ein Antiviren-Programm!

Verbreitung von AV-Programmen

Zahlen zu AV-Installationen

- AVG Antivirus Free (32 & 64 bit) 22.3M
- avast Free Antivirus 19.4M
- Ad-Aware Free Antivirus 9.2M

jeweils in Millionen Downloads bei Chip (Windows)

Virtualisierung I

Virtualisierung

Idee: Wir tun nur so, als würden wir verdächtigen Code laufen lassen, überwachen tatsächlich seine Verhaltensweise

Firewalls I

Firewall

Idee: Ein- und ausgehende Kommunikation überwachen, um Kommunikation von Malware zu verhindern/ Malware zu finden

Problem

Sobald die Kommunikation verschlüsselt abläuft, wird die Überwachung beliebig kompliziert

AV-Browser I

Antiviren-Browser

Idee: Wir halten den Nutzer davon ab, schädliche Dateien herunterzuladen, indem wir einen Browser bereitstellen, der gefährliche Websites u.Ä. blockiert

Wirksame Maßnahmen gegen Viren

Zitat

"We cant write secure software. Why are people suprised that we also can not write secure security software?"



Quellen I

- blog.fefe.de
- sherpablog.marketingsherpa.com/wp-content/uploads/2016/02/Snake-Oil-Cures-All.jpeg
- itwissen.info/definition/lexikon/ (diverse Definitionen)
- de.wikipedia.org/wiki/Schadprogramm
- av-test.org/de/statistiken/malware/
- netmarketshare.com/operating-system-marketshare.aspx?qprid=10&qpcustomd=0
- bsi.bund.de/DE/Publikationen/Lageberichte/bsi-lageberichte.html
- Chip.de (diverse AV-Downloadseiten)
- bugs.chromium.org/p/project-zero/issues/detail?id=769
- de.urbandictionary.com/define.php?term=Startkeylogger

Quellen II

- $\bullet \ \ \mathsf{bugs.chromium.org/p/project-zero/issues/detail?id} = 564\&\mathit{redir} = 1$
- news.softpedia.com/news/avast-safezone-browser-lets-attackers-access-your-filesystem-499990.shtml
- imgur.com/Smwnzx3
- www.heise.de/security/meldung/Authentifikation-von-McAfees-Enterprise-Security-Manager-loechrig-3036068.html
- www.heise.de/security/meldung/Symantec-Endpoint-Protection-Gefaehrlicher-Sicherheitsluecken-Cocktail-2768461.html
- thehackernews.com/2015/07/bitdefender-hacked.html?m=1
- www.heise.de/mac-and-i/meldung/Apple-Anti-Viren-Apps-fuer-iOS-irrefuehrend-2581916.html
- www.heise.de/security/meldung/Antiviren-Software-und-Apples-Schutzmechanismen-fuer-Mac-OS-X-nutzlos-2620049.html